

Creación del Modelo Regresión Lineal.

Procedimiento básico

1. Obtener el dataframe desde un dataset. Revisa toda la información del df. Realiza la limpieza de datos si es necesario.
2. Determinar las características de las etiquetas para X e Y
3. Dividir los datos en: datos de entrenamiento y en datos de prueba, con la función `train_test_split`
4. Crea el modelo con la clase **LinearRegression()**
`modelo_RL_simple=LinearRegression()`
5. Entrena el modelo con la función `fit`
`modelo_RL_simple.fit(X_procesada,Y_procesada)`
6. Utiliza el modelo para realizar la predicción, mediante la función `predict`
7. evalúa el modelo. Calcula el error cuadrático medio

values.reshape

la instrucción `values.reshape((-1, 1))` Suele ser un dolor de cabeza cuando estás empezando en Machine Learning, pero es un paso fundamental para que scikit-learn entienda tus datos.

Aquí tienes la explicación sencilla de qué está pasando exactamente en ese código:

1. El problema: ¿Qué son .values y por qué la forma importa?

Por defecto, `ingre_df['gastos']` (tu variable Y) es una **Serie de Pandas**. Si miras su estructura interna, es básicamente una lista unidimensional (un vector plano).

- `.values`: Convierte esa Serie de Pandas en un **arreglo de NumPy** (ej. `[100, 200, 300]`).
- El problema es que `LinearRegression` de `sklearn` es muy estricto: **siempre espera una matriz de dos dimensiones (filas, columnas)** tanto para las características (X) como para las etiquetas (Y) si vas a entrenar el modelo. Espera algo como `[[100], [200], [300]]`.

2. La solución: ¿Qué hace `reshape((-1, 1))`?

El método `.reshape()` cambia la "forma" de tu arreglo sin cambiar los datos que contiene.

La sintaxis recibe dos argumentos: (filas, columnas). Al pasarle (-1, 1), le estás dando una instrucción muy específica a Python:

- **El 1 (Columnas):** Le dice a NumPy: *"Quiero que el arreglo final tenga exactamente 1 columna"*.
- **El -1 (Filas):** Es un truco o comodín. Le dice a NumPy: *"No sé cuántas filas tengo (o me da pereza contarlas), así que **calcula tú automáticamente el número de filas necesario para que todos los datos quepan en una sola columna**"*.

Visualmente ocurre esto:

Si tus datos originales de ingresos o gastos se veían así (una sola fila/lista horizontal):

[10, 20, 30, 40] (*Dimensión: (4,)*)

Después de aplicar `.reshape((-1, 1))`, se transforman en una columna vertical:

[[10],

[20],

[30],

[40]]

Error Cuadrático Medio (ECM)

El error cuadrático medio (ECM), también conocido como MSE (Mean Squared Error) en inglés, es una medida estadística que se utiliza para evaluar la calidad de un modelo predictivo. En términos sencillos, nos indica qué tan lejos están, en promedio, las predicciones de nuestro modelo de los valores reales.

¿Cómo se calcula el ECM?

1. **Calcular la diferencia entre el valor real y el valor predicho para cada dato:** Para cada punto de datos, restamos el valor que nuestro modelo ha predicho del valor real que conocemos.
2. **Elevar al cuadrado cada diferencia:** Elevamos al cuadrado cada una de las diferencias obtenidas en el paso anterior. Esto sirve para penalizar más los errores grandes, ya que al elevar al cuadrado un número, el resultado se vuelve mucho más grande.

3. **Calcular el promedio:** Sumamos todos los valores obtenidos en el paso anterior y los dividimos por el número total de datos. Esto nos da un valor promedio del error al cuadrado.

Fórmula:

$$ECM = (1/n) * \sum (y_i - \hat{y}_i)^2$$

Donde:

- **n:** Número total de datos
- **y_i:** Valor real del dato i
- **$\hat{y}_i$:** Valor predicho por el modelo para el dato i
- **Σ :** Sumatoria

Ejemplo:

Imagina que queremos predecir la temperatura máxima de una ciudad y nuestro modelo ha hecho las siguientes predicciones:

Día Temperatura real Temperatura predicha (Real - Predicho)^2

1	25	23	4
2	28	27	1
3	30	32	4

El ECM sería: $(4 + 1 + 4) / 3 = 3$.

¿Por qué es importante el ECM?

- **Evaluación de modelos:** Se utiliza para comparar diferentes modelos y elegir el que tenga el menor ECM.
- **Optimización de modelos:** Al minimizar el ECM, podemos ajustar los parámetros de nuestro modelo para obtener mejores resultados.
- **Interpretación:** Aunque el ECM no tiene una interpretación directa en unidades físicas, nos proporciona una medida numérica de la precisión de nuestro modelo.

Consideraciones adicionales:

- **Raíz del Error Cuadrático Medio (RMSE):** A veces, en lugar de utilizar el ECM, se utiliza la raíz cuadrada del ECM (RMSE). Esto nos permite obtener una medida de error en las mismas unidades que nuestros datos originales, lo que puede facilitar la interpretación.
- **Otras métricas:** Existen otras métricas de error como el error absoluto medio (MAE) o el error porcentual absoluto medio (MAPE) que pueden ser más adecuadas dependiendo del problema y los datos.

En resumen, el error cuadrático medio es una herramienta fundamental en el campo del aprendizaje automático y la estadística para evaluar la calidad de los modelos predictivos. Al comprender cómo se calcula y se interpreta, podemos tomar decisiones informadas sobre la selección y el ajuste de nuestros modelos.